Rutas eléctricas: benchmark

Instancias del desafío, escalabilidad y aporte incremental de Amazon Bedrock.

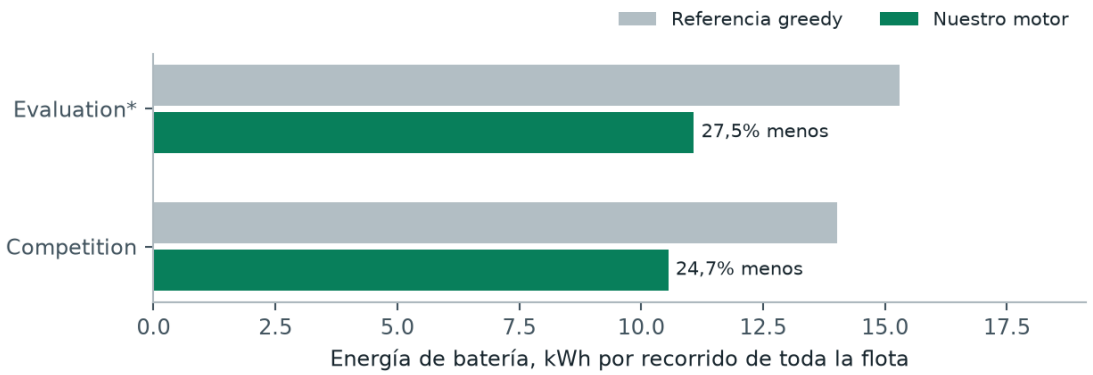
1. Instancias de 20 entregas y 60 cargadores

Dos Nissan Leaf disponibles, SoC inicial 60%. Capacidad útil de 24 kWh y reserva de 2,4 kWh supuestas. Base sin jornada, ventanas ni capacidad de paquetes. Energía estimada por distancia con 0,15677 kWh/km calibrados en eVED.

Entrada	Entregas	kWh	Solver, s	Desde CSV, s	Gap energía
Competition	20/20	10,5577	0,054	31,4	0,227%
Evaluation*	20/20	11,0828	0,049	31,5	0,000%

Rutas de la semilla 0; tiempos medianos de tres corridas estándar. «Desde CSV» suma etapas medidas, usando GraphML y resumen eVED existentes. Excluye su descarga y adquisición originales. Gap objetivo: 0,5%; cumplirlo no significa energía óptima exacta.

Preprocesamiento: 106 746 nodos viales → 81 servicios (99,92% menos nodos). Caminos mínimos: 1,55 s en Competition. Se conservan las calles para expandir y validar la solución.



Referencia: una inserción greedy, un arranque y sin recarga. Los ahorros se calculan solo si ambas rutas atienden exactamente los mismos clientes.

Por recorrido	Δ kWh EV	Δ kg CO_2 EV	Δ USD EV	Δ kg CO_2 Diésel→EV	Δ USD Diésel→EV
Competition	3,469	1,608	0,601	23,98	15,92
Evaluation*	4,213	1,953	0,730	26,35	17,44

Proyección ilustrativa Competition: 300 recorridos equivalentes/año dan 1 041 kWh menos por optimización. El escenario combinado diésel→EV optimizado daría 7,19 t CO_2 y USD 4 777 menos al año. No es actividad observada.

«EV» aísla optimización de rutas eléctricas. «Diésel→EV» combina electrificación y optimización; esos ahorros no se atribuyen al LLM. Los factores optimistas y sus límites aparecen en la página 3.

Decisiones AWS aplicadas en estos ensayos oficiales: Competition: 0; Evaluation: 0. Una respuesta posterior al cierre no mejora la solución.

En ambos casos se verificó la reducción a un tour DFJ que cabe en la batería inicial. Las soluciones usan un vehículo y ninguna recarga. Esto explica su rapidez; las instancias sintéticas con ventanas y recarga son más difíciles.

Las soluciones pasan la validación independiente de retorno y batería sobre las calles. La factibilidad corresponde al estimador utilizado; no incorpora incertidumbre del consumo real.

Ruta competition: vehicle_1: depósito → V12 → V3 → V6 → V19 → V7 → V16 → V15 → V14 → V1 → V18 → V8 → V17 → V4 → V20 → V10 → V2 → V9 → V5 → V11 → V13 → depósito; vehicle_2: inactivo.

Ruta evaluation_access250: vehicle_1: depósito → V10 → V3 → V17 → V6 → V16 → V2 → V20 → V19 → V9 → V13 → V5 → V15 → V7 → V11 → V4 → V18 → V8 → V14 → V1 → V12 → depósito; vehicle_2: inactivo.

* Evaluation usa un acceso bidireccional supuesto de 192,9 m para V16. El escenario original de 100 m lo rechazó; se documentó una variante de 250 m. No se verificó el acceso privado en terreno.

2. ¿Cuánto ayudó el LLM?

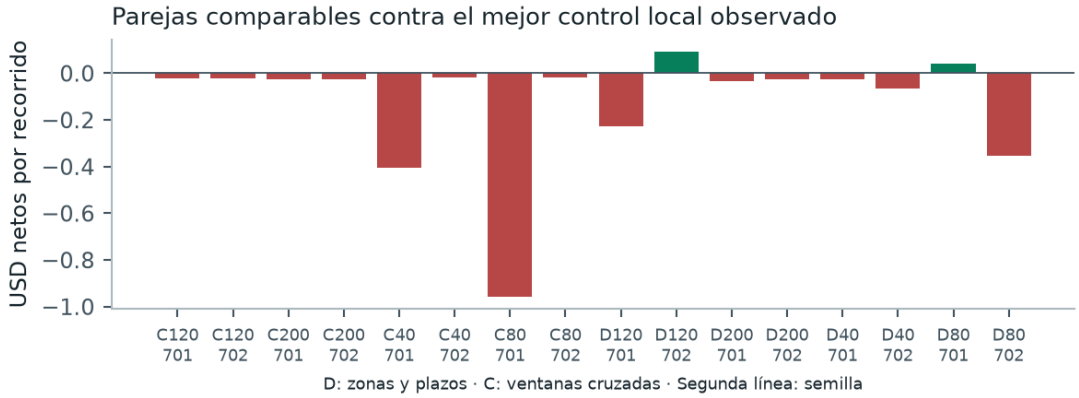
La comparación final usa instancias sintéticas dirigidas: 40, 80, 120 y 200 clientes, dos vehículos, ocho cargadores, dos familias, dos semillas nuevas por tamaño y familia, y cinco políticas. Todas comparten física, presupuesto blando de 45 s y gap objetivo de 0,5%.

Modelo: GPT-5.6 Luna, **us.openai.gpt-5.6-luna**, servido por AWS Bedrock. 32 consultas en 16 corridas con portafolio. Coste medio conocido: USD 0,0228 (16/16 corridas). Inferencia completada mediana: 9,46 s, solapada con la búsqueda. Cambios de política: 16/16; fallback parcial o completo: 0/16.

AWS frente a	Δ entregas	Mismos clientes	Gana/pierde/ empata kWh	Δ kWh medio	Δ USD neto (n)
Base	8,9	13/16	10/2/1	3,426	0,571 (13)
Fija ajustada	0,0	16/16	11/4/1	2,369	0,388 (16)
Reglas	0,0	16/16	5/4/7	-0,247	-0,065 (16)
AWS solo tuning	10,5	11/16	9/2/0	5,343	0,926 (11)
Mejor local observado	0,0	16/16	3/6/7	-0,619	-0,130 (16)

Deltas positivos favorecen al LLM. Energía y USD requieren los mismos clientes. La política fija se eligió en un piloto sin AWS. «Reglas» también activa el portafolio y cambia de fase sin inferencia. «Mejor local» elige, a posteriori, el mejor de los tres controles sin AWS en cada instancia. USD usa solo pares con coste conocido; n indica su cantidad.

AWS solo tuning frente al mejor local observado: 11/16 pares con los mismos clientes; Δ energético medio -5,752 kWh. Esta variante no puede seleccionar el nuevo portafolio ni proponer órdenes de clientes.



Caso destacado: dispatch-n120-instance702, AWS + portafolio. Frente a Mejor local observado: 0,661 kWh (1,28%), 0,306 kg CO_2 y USD 0,0933 netos por recorrido.

Gap energético observado: 30,27%. Proceso completo: 46,36 s. La mejora de energía no implica haber probado el óptimo energético.

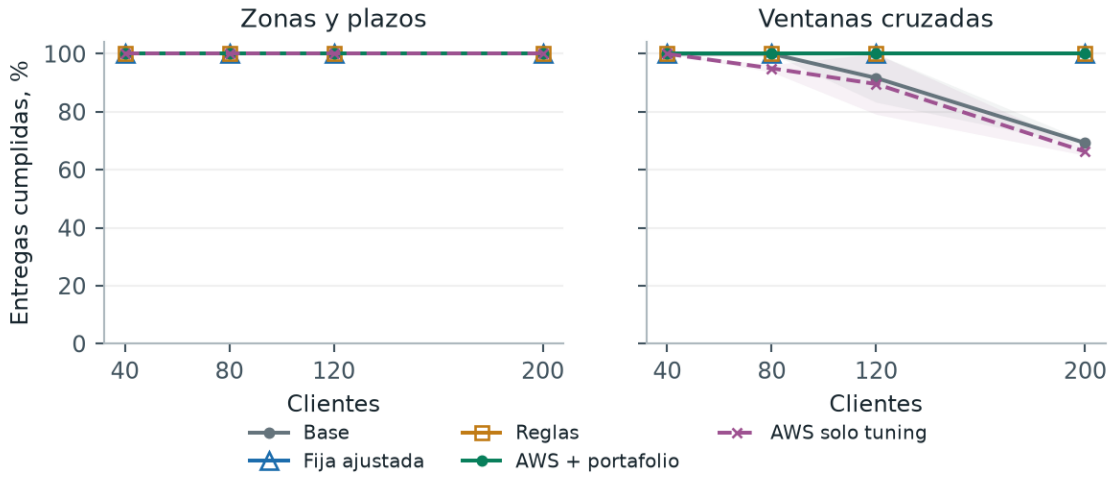
Decisiones aplicadas: before_search: rebuild_strategy: window_waves, rebuild_seconds: 20.0; first_full_service: rebuild_strategy: electric_local

Este ejemplo y su variante AWS se eligieron después de observar los resultados. La tabla y los datos conservan también pérdidas, empates y fallos; no es una estimación de un caso típico.

Demo favorable de la versión anterior B, a 60 s: crossed-n80-instance501 ahorró 14,003 kWh (10,83%), 6,490 kg CO_2 y USD 2,407 netos frente al mejor control local observado. Caso elegido a posteriori; C incorporó controles más fuertes. Las dos versiones se informan por separado.

El LLM selecciona estrategias implementadas y presupuestos dentro del tiempo disponible. SCIP resuelve; el reparador calcula calles, batería y recargas; un validador independiente comprueba las rutas. El LLM no cambia las restricciones ni emite certificados.

3. Escalabilidad y alcance



Líneas: media de dos semillas por punto. Bandas: mínimo y máximo observados, sin interpretación de confianza estadística. Curvas coincidentes: igual cobertura.

Política	Todas ≤45 s	PAR2, s	Proceso med., s	Gap ≤0,5%
Base	13/16	25,85	46,09	0/16
Fija ajustada	16/16	0,41	46,15	0/16
Reglas	16/16	0,40	46,04	0/16
AWS + portafolio	16/16	7,04	46,32	0/16
AWS solo tuning	11/16	34,54	46,20	0/16

PAR2 penaliza no completar las entregas dentro del presupuesto con 90 s; menor es mejor. Evita declarar aceleración descartando los casos difíciles. El proceso incluye carga del snapshot, inferencia solapada, solver, validación y escritura.

Supuestos optimistas de Michigan / USD

Electricidad comercial: USD 0.1646/kWh; diésel: USD 1.6535/L. Furgón diésel hipotético: 12 L/100 km; eficiencia para estimar electricidad comprada 95%. Electricidad: 0.4403 kg CO_2/kWh generado; diésel: 2.6893 kg CO_2/L. Se repone también la batería inicial.

Δ USD neto = (E referencia − E LLM) / 0,95 × 0,1646 − coste incremental de tokens. Las tarifas AWS por millón son USD 0,22 entrada, 1,32 salida, 0,275 escritura de caché y 0,022 lectura. Costes desconocidos quedan ND.

Los factores son aproximaciones operacionales, no mediciones de CO_2 ni una factura de AWS. No incluyen emisiones de cómputo, fabricación, inversión, mantenimiento, salarios, colas ni sobreprecio de carga rápida. El furgón diésel no tiene equivalencia de capacidad de carga acreditada. Las instancias sintéticas se diseñaron para favorecer decisiones de portafolio; no prueban una ventaja general de los LLM.

Fuentes y reproducción

[1] EIA: electricidad Michigan, julio 2026. [2] EIA: diésel Midwest, 12 oct 2026. [3] EPA eGRID2023 Rev2, RFCM y factor CO_2 del diésel. [4] AWS: GPT-5.6 Luna, Standard Geo CRIS. Consultadas 16 oct 2026.

Main de partida: **94a4e1d**. Versión de la cohorte C: **a04a884**. Validación del código: 967 pruebas y 37 subpruebas. Entradas, semillas, fallos, trazas SCIP, respuestas de AWS, factores y hashes acompañan este PDF en los CSV/JSON. Los testigos sintéticos nunca se entregaron al solver ni al LLM. Equipo: Apple M4 Pro, 24 GB; un hilo SCIP y resoluciones en serie.

4. Flota y control de búsqueda

Estudios adicionales con semillas nuevas y presupuesto de 30 s por resolución. Sus resultados se mantienen separados de la comparación principal de 45 s.

De 2 a 8 vehículos, con 200 clientes

Vehículos	Base: entregas	Reglas: entregas	AWS: entregas	AWS proceso, s
2	62,8%	100,0%	100,0%	31,51
4	60,2%	100,0%	99,8%	31,51
8	59,2%	100,0%	79,2%	36,53

Código de la cohorte C, ventanas cruzadas y dos semillas por tamaño de flota. Se muestran medias de cobertura y medianas de tiempo. El gráfico y los resultados individuales están en el paquete de datos.

Aviso temprano y mejora eléctrica reanudable

La versión posterior avisa cuando encuentra cobertura completa; si AWS está ocupado, conserva el evento para el siguiente callback disponible. También permite continuar una mejora eléctrica interrumpida por tiempo y elimina el máximo fijo de 20 mejoras. Las reglas locales reciben las mismas correcciones. Esta variante pasó 970 pruebas y 37 subpruebas.

Comparación	Δ entregas	Mismos clientes	Δ kWh medio	Δ USD neto (n)
AWS base / reglas	0,75	3/4	-1,670	-0,3123 (3)
AWS desde fija / fija	-0,25	3/4	3,506	0,5844 (3)
AWS desde fija / reglas	0,50	3/4	-0,016	-0,0258 (3)
AWS nuevo / anterior	0,25	3/4	0,548	0,0908 (3)
AWS desde fija: nuevo / anterior	0,00	4/4	0,603	0,1046 (4)

Positivo favorece al primer método. «Desde fija» parte de la política elegida por el piloto C; el control recibe exactamente el mismo arranque. La extensión se registró antes de resolver la semilla 1301. Son cuatro instancias por contraste; no una prueba de ventaja general.

Demo con 200 clientes: dispatch-n200-instance1301. AWS y la fija atienden 200/200. AWS ahorra 7,533 kWh (11,04%), 3,491 kg CO_2 y USD 1,280 netos, descontando USD 0,0251 en tokens.

Las reglas locales obtuvieron 60,667 kWh; AWS, 60,667 kWh. Ejemplo elegido a posteriori. La mejora frente a la fija no demuestra ventaja frente a esas reglas ni optimalidad energética.

Qué hizo AWS: acortó las épocas de pricing de 12 a 8 y luego 6 s, y cambió de reconstrucción por ventanas a mejora eléctrica. El motor aceptó 74 mejoras locales. Gap energético final: 41,32%. Propuso cortes subset-row, pero no se ejecutó ninguno.

Qué conservar para la presentación

El ahorro de las rutas oficiales, el aporte de AWS frente a cada referencia y el efecto de mejorar el código son resultados distintos. Los CSV conservan las pérdidas y los costos desconocidos. Las transcripciones permiten revisar la decisión propuesta, los cambios aceptados y las acciones ejecutadas.

Este informe reúne **436 corridas**, incluidos pilotos y **4 fallos**. Costo conocido de las consultas de las comparaciones sintéticas: **USD 2,190**; 3 corridas sintéticas tienen costo desconocido. Se excluyen del importe los diagnósticos de desarrollo y las consultas oficiales sin uso confirmado.